

MASTER INTELLIGENCE ARTIFICIELLE
TRAVAUX DIRIGÉS — MACHINE LEARNING

TD N° 02 : Analyse Exploratoire et Preprocessing des Données (EDA)

Réalisé par :
Ayman CHABBAKI
Groupe : G1

Sous la direction de :
Pr. BEN LAHMAR EL Habib

Année Universitaire 2025–2027

Table des matières

1	Introduction	2
2	Diagnostic et Détection	2
2.1	Simulation et Profil des Valeurs Manquantes	2
2.2	Détection des Valeurs Aberrantes (Outliers)	2
3	Stratégies d'Imputation	3
3.1	Variables Numériques	3
3.2	Variables Catégorielles	3
4	Encodage et Normalisation	3
4.1	Encodage des Variables Catégorielles	3
4.2	Choix du Scaler	4
5	Conclusion et Synthèse	4

1 Introduction

Ce compte rendu présente les travaux de préparation et d'analyse exploratoire des données (EDA) effectués sur le jeu de données *BankChurners*. L'objectif de ce TD est de formuler une démarche rigoureuse de *preprocessing* (diagnostic des valeurs manquantes, détection des valeurs aberrantes, imputation, encodage et mise à l'échelle) afin de construire un **ColumnTransformer** robuste pour de futures modélisations visant à prédire l'attrition client (churn).

2 Diagnostic et Détection

2.1 Simulation et Profil des Valeurs Manquantes

Le dataset d'origine ne comportant pas de données manquantes, nous avons simulé un mécanisme de disparition totalement aléatoire (MCAR - *Missing Completely At Random*) sur les variables **Gender** (8%), **Education_Level** (12%) et **Total_Trans_Amt** (5%).




FIGURE 1 – Profil des valeurs manquantes simulées.

2.2 Détection des Valeurs Aberrantes (Outliers)

La détection via la méthode de l'écart interquartile (IQR) a révélé que les variables financières, notamment **Credit_Limit** (9.7% d'outliers) et **Total_Trans_Amt** (8.8% d'outliers), comportent un grand nombre de valeurs extrêmes.




FIGURE 2 – Boxplots illustrant les valeurs aberrantes des variables clés.

3 Stratégies d'Imputation

3.1 Variables Numériques

Pour la variable asymétrique `Total_Trans_Amt`, trois stratégies ont été comparées : moyenne, médiane et constante (0). L'imputation par la **médiane** a été retenue, car elle résiste mieux aux valeurs extrêmes que la moyenne et ne crée pas de pics artificiels trompeurs comme l'imputation par zéro.




FIGURE 3 – Comparaison des stratégies d'imputation sur la distribution de `Total_Trans_Amt`.

3.2 Variables Catégorielles

Pour les variables catégorielles, nous avons utilisé l'imputation par le mode pour `Gender`. En revanche, pour `Education_Level` qui contenait déjà une modalité "*Unknown*", l'imputation par constante (*fill_value='Unknown'*) permet de préserver la cohérence sémantique du dataset.




FIGURE 4 – Impact de l'imputation (Mode vs Unknown) sur les variables catégorielles.

4 Encodage et Normalisation

4.1 Encodage des Variables Catégorielles

Différentes stratégies d'encodage ont été appliquées en respectant la nature des données :

- **Cible et variables binaires** : *Label Encoding* explicite via *map* (ex : *Attrited Customer* $\rightarrow$ 1, *Gender M/F* $\rightarrow$ 1/0).
- **Variables ordinales** (*Education_Level*, *Income_Category*) : *OrdinalEncoder* avec un ordre logique respecté.

- **Variables nominales (Card_Category) :** *One-Hot Encoding* avec `drop='first'` pour éviter la parfaite colinéarité (*dummy trap*).

4.2 Choix du Scaler

Les distributions fortement asymétriques des variables financières ont nécessité une mise à l'échelle spécifique. La comparaison entre le **StandardScaler**, le **MinMaxScaler** et le **RobustScaler** a montré que ce dernier préserve le mieux l'information sans être écrasé par les valeurs extrêmes. Le **RobustScaler** a donc été adopté.




FIGURE 5 – Comparaison de l'effet des scalers sur la variable **Credit_Limit**.

5 Conclusion et Synthèse

Ce TP nous a permis de structurer une démarche de prétraitement reproductible. Les variables financières asymétriques ont bénéficié d'une normalisation par **RobustScaler** et d'une imputation par la médiane, garantissant la résilience face aux outliers. Les variables catégorielles ont été traitées sémantiquement, mêlant imputations modales et constantes, et encodages nominaux ou ordinaux selon les contextes.

Afin de garantir l'absence de fuite de données (*data leakage*), le jeu de données a d'abord été séparé en sous-ensembles d'entraînement et de test. Le **ColumnTransformer** ainsi construit n'a été ajusté (`fit`) que sur les données d'entraînement. L'ensemble de ce pipeline a été exporté dans un fichier `churn_preprocessor.pkl` pour une utilisation directe dans nos futurs modèles prédictifs.