
Compte Rendu de Projet

Modélisation et Évaluation (Machine Learning)

Implémentation de l'algorithme TD3
(Twin Delayed Deep Deterministic Policy Gradient)

Ayman Chabbaki

Groupe : G1

June 7, 2026

1. Introduction

Ce rapport détaille l'implémentation et l'évaluation de l'algorithme d'apprentissage par renforcement **TD3 (Twin Delayed Deep Deterministic Policy Gradient)**. Cet algorithme est spécialement conçu pour résoudre les problèmes de contrôle continu, en surmontant le problème de surestimation des valeurs Q souvent observé dans les méthodes classiques comme DDPG. Le projet a été validé sur l'environnement **Pendulum-v1** du module Gymnasium.

2. Architecture du Modèle

Le modèle utilise une architecture de type *Acteur-Critique* implémentée en PyTorch.

2.1. Le Réseau Acteur (Actor)

L'Acteur détermine la politique déterministe (association d'un état à une action). Son architecture comprend :

- Une couche d'entrée de dimension 3 (correspondant à l'espace d'observation).
- Deux couches cachées denses de 400 et 300 neurones (activation **ReLU**).
- Une couche de sortie utilisant une fonction **Tanh** pour borner les actions entre $[-1, 1]$, multipliées par la suite par la plage d'action maximale (**max_action** = 2.0).

2.2. Le Réseau Critique (Critic)

Afin de limiter la surestimation, l'algorithme TD3 repose sur **deux réseaux Q jumeaux** (Twin Q-Networks) :

- Chaque réseau prend en entrée la concaténation de l'état et de l'action.

- Ils partagent la même structure interne (couches de 400 et 300 neurones).
- Lors du calcul de la cible de l'équation de Bellman, le minimum des deux évaluations est conservé :

$$y = r + \gamma \min (Q_1(s', a'), Q_2(s', a'))$$

3. Mécanismes Spécifiques à TD3

L'implémentation incorpore les trois améliorations fondamentales de l'algorithme TD3 :

1. **Replay Buffer** : Stockage des transitions (s, a, r, s', d) avec une capacité de 1 000 000, permettant l'échantillonnage de batches décorrélés.
2. **Target Policy Smoothing** : Un bruit aléatoire *clippé* est ajouté aux actions sélectionnées par la politique cible pour lisser la fonction de valeur.
3. **Delayed Policy Updates** : La politique (l'Acteur) n'est mise à jour que toutes les d itérations ($d = 2$) par rapport au Critique. Cela garantit une estimation stable de la valeur Q avant de modifier l'Acteur.

4. Expérimentation et Résultats

4.1. Paramètres d'Entraînement

Le modèle a été entraîné avec la configuration suivante :

- $\gamma = 0.99$ (facteur d'escompte)
- $\tau = 0.005$ (mise à jour douce)
- `batch_size = 128`
- `max_timesteps = 20 000`
- Taux d'apprentissage (*Learning Rate*) = 10^{-3}

4.2. Évaluation des Performances

L'entraînement s'est achevé sur une session courte de 20 000 itérations. Lors de l'évaluation sur 5 épisodes déterministes, l'agent a obtenu une **moyenne de récompense de -169.34 ± 96.24**. Ce résultat indique une excellente convergence : l'agent parvient rapidement à maintenir le pendule en équilibre.

5. Conclusion

L'algorithme TD3 a été implémenté et entraîné avec succès. Malgré un nombre réduit d'étapes (20k), la politique s'est stabilisée, résolvant efficacement le problème du Pendulum-v1. Les poids des modèles finaux ont été enregistrés sous `td3_a_chabbaki_actor.pth` et `td3_a_chabbaki_critic.pth` pour des inférences ultérieures.



Figure 1: Évolution des récompenses par épisode au cours de l'entraînement.