

MASTER INTELLIGENCE ARTIFICIELLE
TRAVAUX DIRIGÉS — MACHINE LEARNING

TD N° 03 : Modélisation et Évaluation
Algorithme TD3 (Reinforcement
Learning)

Réalisé par :
Ayman CHABBAKI
Groupe : G1

Sous la direction de :
Pr. BEN LAHMAR EL Habib

Année Universitaire 2025–2027

Table des matières

1	Introduction	2
2	Environnement et Architecture	2
2.1	Configuration de l'Environnement	2
2.2	Architecture des Réseaux (Actor et Critic)	2
3	Apprentissage et Entraînement	2
3.1	Hyperparamètres du Modèle	2
3.2	Boucle d'entraînement et Mécanismes Clés	2
4	Résultats et Évaluation	3
5	Conclusion	3

1 Introduction

Ce compte rendu détaille l'implémentation de l'algorithme d'apprentissage par renforcement TD3 (*Twin Delayed Deep Deterministic Policy Gradient*) appliqué à un environnement de contrôle continu. Le but de ce projet est de construire les réseaux de neurones *Actor* et *Critic* à l'aide de PyTorch, de configurer la boucle d'entraînement avec un *Replay Buffer*, et d'évaluer les performances de l'agent sur l'environnement standard *Pendulum-v1* de la bibliothèque Gymnasium.

2 Environnement et Architecture

2.1 Configuration de l'Environnement

L'environnement sélectionné est *Pendulum-v1*, un problème classique de contrôle continu.

— **Espace d'observation** : Vecteur continu de 3 dimensions.

— **Espace d'action** : Valeur continue comprise entre $[-2.0, 2.0]$.

Les actions générées par le modèle (comprises entre $[-1, 1]$) sont automatiquement mises à l'échelle pour correspondre aux spécifications de l'environnement.

2.2 Architecture des Réseaux (Actor et Critic)

L'algorithme TD3 repose sur une architecture acteur-critique pour atténuer la surestimation de la fonction de valeur Q .

— **Réseau Actor** : Un perceptron multicouche (MLP) avec deux couches cachées de 400 et 300 neurones, utilisant des fonctions d'activation ReLU, et une sortie tanh pour borner les actions.

— **Réseau Critic** : Implémente la technique *Twin Q-networks* (deux critiques indépendants) pour réduire le biais d'estimation. Chaque réseau partage la même structure (400 et 300 neurones). Lors de l'apprentissage, la valeur minimale entre les deux prédictions est sélectionnée pour le calcul de la fonction de coût.

3 Apprentissage et Entraînement

3.1 Hyperparamètres du Modèle

Les performances de l'algorithme TD3 dépendent fortement des hyperparamètres. Pour cette expérimentation, les valeurs suivantes ont été adoptées :

— **Facteur d'actualisation** (γ) : 0.99

— **Taux de mise à jour douce** (τ) : 0.005

— **Bruit de politique** : 0.2 (écrêté à 0.5)

— **Délai de la politique** : 2 itérations

— **Taux d'apprentissage (Actor & Critic)** : 10^{-3}

— **Taille du batch** : 128

3.2 Boucle d'entraînement et Mécanismes Clés

Le processus d'apprentissage s'est étalé sur 20 000 *timesteps* (version abrégée pour la démonstration). Les mécanismes clés suivants ont été intégrés :

1. **Replay Buffer** : Stockage des transitions pour briser la corrélation temporelle lors de l'échantillonnage des batches d'entraînement.
2. **Target Policy Smoothing** : Ajout d'un bruit écrêté aux actions sélectionnées par la politique cible pour régulariser l'apprentissage.
3. **Delayed Policy Updates** : Le réseau Actor n'est mis à jour qu'une itération sur deux par rapport au réseau Critic, stabilisant ainsi l'apprentissage.

4 Résultats et Évaluation

L'évaluation de la politique déterministe en fin d'entraînement montre que le modèle commence à converger vers des comportements viables pour l'environnement du pendule inversé.




FIGURE 1 – Évolution des récompenses par épisode lors de l'entraînement de l'agent TD3 sur l'environnement Pendulum-v1.

Les résultats quantitatifs sur 5 épisodes d'évaluation génèrent un score moyen de **-169.34 ± 96.24**. Bien qu'il s'agisse d'un cycle d'entraînement court (20 000 *timesteps* au lieu des 200 000 prévus), la courbe de récompenses (Figure 1) montre une progression claire et une augmentation globale des gains au fil des épisodes.

5 Conclusion

Ce travail pratique a permis de consolider les principes fondamentaux de l'apprentissage par renforcement profond en implémentant l'algorithme TD3 avec PyTorch. L'utilisation du lissage des actions cibles et des réseaux critiques jumeaux prouve son efficacité pour stabiliser la convergence dans des environnements à espace d'action continu. Une augmentation du nombre d'itérations d'entraînement (jusqu'au maximum théorique défini) permettrait à l'agent de stabiliser complètement le pendule de manière optimale.