

MASTER INTELLIGENCE ARTIFICIELLE
TRAVAUX DIRIGÉS — MACHINE LEARNING

TD N° 04 : Régression Linéaire
& Régression Logistique

Réalisé par :
Ayman CHABBAKI
Groupe : G1

Sous la direction de :
Pr. BEN LAHMAR EL Habib

Année Universitaire 2025–2027

Table des matières

1	Introduction	2
2	Partie 1 : Régression Linéaire (California Housing)	2
2.1	Implémentation de la Descente de Gradient	2
2.2	Régression Linéaire Multiple	2
3	Partie 2 : Régression Logistique (BankChurners)	3
3.1	Modélisation et Interprétation	3
3.2	Analyse des Métriques et du Seuil de Décision	3
3.3	Impact de la Régularisation (L1 vs L2)	4
4	Conclusion	4

1 Introduction

Ce compte rendu synthétise les travaux réalisés lors du TD4 portant sur les algorithmes fondamentaux d'apprentissage supervisé : la régression linéaire et la régression logistique. L'objectif principal de ces travaux pratiques est de maîtriser l'implémentation de la descente de gradient, l'interprétation des coefficients, ainsi que l'évaluation des modèles de machine learning sur deux jeux de données distincts : *California Housing* (pour la régression) et *BankChurners* (pour la classification).

2 Partie 1 : Régression Linéaire (California Housing)

2.1 Implémentation de la Descente de Gradient

Nous avons débuté par l'implémentation algorithmique de la descente de gradient depuis zéro ("from scratch"). Cela a permis d'observer concrètement le mécanisme d'optimisation visant à minimiser la fonction de coût (Mean Squared Error).




FIGURE 1 – Évolution de la fonction de coût lors de la descente de gradient.

2.2 Régression Linéaire Multiple

En utilisant la bibliothèque `scikit-learn`, un modèle de régression linéaire multiple a été entraîné sur le jeu de données *California Housing*. L'étape de standardisation des caractéristiques s'est révélée cruciale. Les résultats ont démontré qu'une régression multiple améliore considérablement le coefficient de détermination (R^2) par rapport à un modèle n'utilisant qu'une seule caractéristique.




FIGURE 2 – Comparaison entre les valeurs réelles et les valeurs prédites.

3 Partie 2 : Régression Logistique (BankChurners)

3.1 Modélisation et Interprétation

Pour la prédiction de l'attrition des clients (*churn*), nous avons eu recours à la régression logistique. Les coefficients obtenus par ce modèle sont particulièrement interprétables. Leur conversion en ratios de cotes (*Odds Ratios*) a permis de traduire les sorties mathématiques en informations décisionnelles claires pour le contexte métier bancaire.




FIGURE 3 – Matrice de confusion du modèle de régression logistique.

3.2 Analyse des Métriques et du Seuil de Décision

Une analyse approfondie via les courbes ROC et Précision-Rappel a mis en évidence les limites des seuils par défaut face à un jeu de données déséquilibré. L'ajustement de ce seuil de classification, notamment par l'indice de Youden ou sous des contraintes métier de rappel, modifie significativement la précision globale du modèle.




FIGURE 4 – Courbe ROC et AUC.





FIGURE 5 – Courbe Précision-Rappel.

3.3 Impact de la Régularisation (L1 vs L2)

Nous avons comparé les régularisations L1 (*Lasso*) et L2 (*Ridge*). La régularisation L1 a induit de la parcimonie (annulation de certains coefficients), ce qui est extrêmement utile pour l'explicabilité du modèle. À l'inverse, la pénalité L2 a permis de réduire l'amplitude des coefficients sans éliminer de caractéristiques de manière abrupte.

FIGURE 6 – Évolution des coefficients selon la force de régularisation (C).

4 Conclusion

Ce TD4 a permis de mettre en perspective les techniques de régression linéaire et logistique, tout en validant numériquement les solutions analytiques par l'implémentation de la descente de gradient.

L'étude a montré la valeur de la combinaison de prédicteurs pertinents pour la prédiction des prix immobiliers, tout en soulignant la nécessité d'une mise à l'échelle rigoureuse des données. Sur le problème de classification bancaire, l'optimisation des seuils s'est avérée indispensable pour gérer le déséquilibre des classes. Enfin, l'utilisation de la validation croisée a permis de sélectionner une force de régularisation appropriée maximisant le score F1. Le choix du modèle et de ses hyperparamètres dépend ultimement de la nature de la cible (continue ou binaire) et des exigences métier en matière d'interprétabilité et de robustesse.